

Библиотеки для анализа данных

Гейне М.А.

24.10.2025

Одни из сильных сторон Python - большое сообщество и разнообразие библиотек. И именно эти особенности делают Python столь применимым для анализа данных

Стек библиотек для анализа данных:

- NumPy;
- Pandas;
- Matplotlib;
- SciPy;
- Sklearn

NumPy

- NumPy - это фундаментальная библиотека Python для численных вычислений
- Она обеспечивает поддержку больших многомерных массивов и матриц, а также набор математических функций для работы с ними
- Она является основой для многих других библиотек для работы с данными, таких как Pandas и SciPy

Основные особенности

- **ndarray (N-dimensional array):** Эффективно обрабатывает большие массивы данных, используя однородные массивы. По сравнению со списками Python ndarray быстрее и занимает меньше памяти
- **Бродкастинг:** Поддерживает поэлементные операции между массивами разной формы, позволяя эффективно вычислять без циклов
- **Векторизация:** Устраняет необходимость в явных циклах, ускоряя математические операции над массивами
- **Математические функции:** Предлагает широкий спектр математических операций (таких как тригонометрические, статистические и алгебраические функции) над массивами

Почему NumPy?

- Массивы NumPy гораздо эффективнее списков Python как по скорости, так и по потреблению памяти
- Обеспечивает основу для более продвинутых научных вычислений (например, анализ данных, машинное обучение)
- Крайне важен для матричных операций и работы с многомерными данными в машинном обучении и научном моделировании

Причины производительности

1. Однородность типов данных и массивы C

- Массивы NumPy хранятся в смежных блоках памяти и требуют, чтобы все элементы были одного типа данных (например, все float или все int). Списки Python могут содержать объекты разных типов, что приводит к большим затратам памяти и проверке типов
- Такая однородная структура позволяет NumPy напрямую взаимодействовать с низкоуровневым кодом на C и Fortran, который оптимизирован для численных вычислений

2. Размещение в памяти и эффективный доступ

- **Смежная память:** Массивы NumPy размещаются в памяти смежно. Это гарантирует, что при обращении к элементам массива процессор сможет эффективнее кэшировать данные и быстро их получать
- **Отказ от расходов на указатели:** Списки Python представляют собой коллекции указателей на объекты, и доступ к элементам предполагает разыменовывание этих указателей. NumPy, с другой стороны, хранит элементы плотно упакованными, избегая расходов на указатели

3. Векторизация

- NumPy выполняет операции над целыми массивами сразу, без необходимости перебирать отдельные элементы в коде Python. Это называется векторизацией, когда операции применяются непосредственно к массивам, в том числе с помощью скомпилированного кода на языке C
- Например, сложение двух массивов по элементам выполняется одной инструкцией на уровне C, а не итерацией по каждому элементу в цикле Python

4. Оптимизированный бэкенд на языках C и Fortran:

- NumPy - это обертка вокруг таких высокооптимизированных библиотек, как BLAS (Basic Linear Algebra Subprograms) и LAPACK (Linear Algebra Package). Эти библиотеки реализованы на низкоуровневых языках, таких как C и Fortran, которые намного быстрее интерпретируемого кода Python
- Многие тяжелые вычисления (например, умножение матриц, линейная алгебра) перекладываются на эти оптимизированные библиотеки

5. Эффективное использование кэша процессора:

- Поскольку массивы NumPy являются смежными в памяти, при обращении процессора к одному элементу, скорее всего, соседние элементы также будут загружены в кэш. Это увеличивает скорость доступа к данным при последующих операциях за счёт **локальности ссылок**

6. Низкоуровневые SIMD-инструкции:

- NumPy может использовать преимущества **SIMD (Single Instruction, Multiple Data)** инструкций CPU, когда одна операция может быть применена к нескольким блокам данных одновременно. Это может значительно ускорить векторные операции над массивами

```
import numpy as np

# 1. Create a NumPy array (1D and 2D)
array1 = np.array([1, 2, 3, 4, 5])
array2 = np.array([[1, 2, 3], [4, 5, 6], [7, 8, 9]])

# 2. Vectorized operations
result_add = array1 + 10
result_mul = array1 * 2

# 3. Broadcasting
broadcast_result = array2 + array1[:3]

# 4. Indexing and slicing
element = array2[1, 2]
row_slice = array2[1, :]

# 5. Statistical operations (mean, sum, etc.)
mean_val = np.mean(array2)
sum_along_axis = np.sum(array2, axis=0)

# 6. Aggregating conditions (boolean indexing)
greater_than_five = array2[array2 > 5]
```

```
Original 1D array: [1 2 3 4 5]
Original 2D array:
[[1 2 3]
 [4 5 6]
 [7 8 9]]
Result of adding 10: [11 12 13 14 15]
Result of multiplying by 2: [ 2  4  6  8 10]
Broadcasting result:
[[ 2  4  6]
 [ 8 10 12]
 [12 14 16]]
Accessed element: 6
Second row slice: [4 5 6]
Mean of array2: 5.0
Sum along columns: [12 15 18]
Elements greater than 5: [6 7 8 9]
```

Pandas

- Pandas - это универсальная и мощная библиотека анализа данных на языке Python, широко используемая для работы со структурированными данными
- Pandas построена поверх NumPy и в значительной степени опирается на ее базовые структуры данных, что делает эти две библиотеки тесно взаимосвязанными
- Если NumPy - это мощные *массивы*, то Pandas - мощные *таблицы*

Структуры данных

- **Series:** Одномерный маркированный массив, способный хранить данные любого типа (целые числа, с плавающей запятой, строки и т. д.). По сути, это столбец в таблице
- **DataFrame:** Двумерная структура данных с метками, похожая на Excel таблицу или таблицу SQL. Она состоит из нескольких серий, выровненных в формате таблицы
- Pandas использует **массивы NumPy** в качестве основной структуры данных для своих Series и DataFrames. Каждый столбец в Pandas DataFrame - это, по сути, **маркированный массив NumPy** (Series), что позволяет эффективно хранить данные и манипулировать ими
- **Однородные типы данных:** Как и массивы NumPy, каждый столбец Pandas (серия) содержит один тип данных, но в отличие от NumPy, фреймы Pandas DataFrame могут содержать несколько типов данных (например, целое число, плавающая запятая, строка) в разных столбцах

Методы обработки данных

- **Индексация и интервалы:** Pandas предоставляет такие мощные методы, как `.loc[]` , `.iloc[]` для выбора строк и столбцов по меткам или позициям
- **Обработка отсутствующих данных:** Pandas имеет встроенную функциональность для обработки значений NaN (Not a Number) с помощью таких методов, как `.dropna()` и `.fillna()`

- Pandas имеет широкий набор встроенных методов для статистики (`mean()` , `sum()` , `std()` , `min()` , `max()` и т. д.), а также для агрегирования, фильтрации, сортировки и изменения формы данных
- Pandas может работать с широким спектром форматов файлов, таких как CSV, Excel, базы данных SQL, JSON и другие. Его функции, такие как `read_csv()` , `to_csv()` , `read_excel()` и т.д., упрощают загрузку и сохранение данных
- Pandas хорошо сочетается с другими библиотеками для работы с данными, такими как NumPy, Matplotlib и Scikit-learn. Например, он легко конвертирует массивы NumPy в Pandas DataFrames, а его структуры данных часто используются в качестве входных данных для моделей машинного обучения

Почему Pandas?

- **Удобство:** Абстрагируется от большей части сложностей, связанных с анализом данных, что упрощает выполнение таких распространенных задач, как очистка, преобразование и визуализация данных
- **Производительность:** Хотя Pandas не так быстр, как NumPy, для численных вычислений, он оптимизирован для работы с данными и эффективно работает с большими наборами данных
- **Выразительный синтаксис:** Pandas предлагает лаконичный и понятный синтаксис для сложных операций, что делает его удобным выбором как для аналитиков, так и для разработчиков

```

import pandas as pd

# Create a DataFrame with labeled index and columns
data = {
    'Name': ['Alice', 'Bob', 'Charlie', 'David', 'Eva'],
    'Age': [25, 32, 23, 45, 29],
    'City': ['New York', 'Los Angeles', 'Chicago', 'Houston', 'Phoenix'],
    'Salary': [70000, 80000, 50000, 120000, 95000]
}

df = pd.DataFrame(data)
df.index = ['A001', 'A002', 'A003', 'A004', 'A005'] # Setting custom labeled index

# Display the DataFrame
print("DataFrame with labeled index:\n", df)

```

	Name	Age	City	Salary
A001	Alice	25	New York	70000
A002	Bob	32	Los Angeles	80000
A003	Charlie	23	Chicago	50000
A004	David	45	Houston	120000
A005	Eva	29	Phoenix	95000

```
# 1. Querying data with labeled indexing
# Select a row using the label (e.g., 'A002')
row = df.loc['A002'] # Get row for Bob
print("\nData for 'A002' (Bob):\n", row)

# 2. Selecting specific columns for a row
name_and_salary = df.loc['A004', ['Name', 'Salary']] # Get 'Name' and 'Salary' of 'A004' (David)
print("\nName and Salary for 'A004' (David):\n", name_and_salary)
```

```
Data for 'A002' (Bob):
Name          Bob
Age           32
City      Los Angeles
Salary       80000
Name: A002, dtype: object
```

```
Name and Salary for 'A004' (David):
Name      David
Salary   120000
Name: A004, dtype: object
```

```
# 3. Filtering data using condition-based queries
# Query people with Salary greater than 80,000
high_earners = df[df['Salary'] > 80000]
print("\nPeople with Salary greater than 80,000:\n", high_earners)

# 4. Filtering data based on multiple conditions
# Query people who live in 'New York' or have a Salary greater than 90,000
filtered_data = df[(df['City'] == 'New York') | (df['Salary'] > 90000)]
print("\nPeople living in 'New York' or with Salary greater than 90,000:\n", filtered_data)
```

People with Salary greater than 80,000:

	Name	Age	City	Salary
A004	David	45	Houston	120000
A005	Eva	29	Phoenix	95000

People living in 'New York' or with Salary greater than 90,000:

	Name	Age	City	Salary
A001	Alice	25	New York	70000
A004	David	45	Houston	120000
A005	Eva	29	Phoenix	95000

А если не Pandas?

- **Polars** - сверхбыстрая библиотека для работы с DataFrame, написанная на **Rust**
- Как и Pandas, для работы с табличными данными, но спроектирована для максимальной производительности и работы с большими наборами данных (которые не помещаются в память)

Ключевые особенности

- **Написана на Rust:** Дает безопасность работы с памятью и C-подобную скорость без "костылей" Python (GIL)
- **Параллелизм "из коробки":** Polars автоматически использует все ядра вашего процессора для выполнения операций. Pandas, в основном, однопоточный
- **Ленивые вычисления (Lazy API)**

Ленивые вычисления (Lazy vs. Eager)

- Pandas работает в Eager режиме всегда, т.е. он немедленно выполняет заданную операцию
- В Polars доступен Lazy режим: вы описываете *план операций*, и они не исполняются до тех пор, пока вам явно не потребуется результат (метод `.collect()`)
- Преимущество - возможность оптимизации плана перед его исполнением

Ленивые вычисления (Lazy vs. Eager)

- **Pandas:** Вы идете в магазин за молоком. Вернулись. Идете в магазин за хлебом. Вернулись. Идете за яйцами
- **Polars (Lazy):** Вы составляете список (молоко, хлеб, яйца), смотрите на него, понимаете, что все это в одном отделе, идете в магазин один раз и берете все сразу

Polars vs. Pandas: Ключевые отличия

- В Polars **нет индекса** (как `df.index` в Pandas). Это главное отличие в API
- Polars - **колоночный** движок
- Polars *значительно* быстрее Pandas на больших данных (> 1 ГБ) благодаря параллелизму и ленивым вычислениям
- Polars поощряет "чейнинг" (цепочки) методов, что очень хорошо ложится на "ленивый" API

```
import polars as pl

# Eager (похоже на Pandas)
df = pl.DataFrame({
    'temp': [10, 15, 5, 20],
    'city': ['A', 'A', 'B', 'B']
})
avg_temp_eager = df.group_by('city').agg(pl.col('temp').mean())

# Lazy (рекомендуемый способ)
lazy_df = df.lazy() # Начинаем строить план
plan = lazy_df.group_by('city').agg(pl.col('temp').mean())

# Выполняем план
avg_temp_lazy = plan.collect()
```

Polars vs. Pandas

Представим сценарий - таблица на 100 000 000. Pandas:

- `df = pd.read_csv('big_file.csv')`
- `df['new_col'] = df['col_a'] * 2` (Создает новую колонку для 100 млн строк)
- `df_filtered = df[df['col_b'] > 10]` (Фильтрует, оставляя 1000 строк)
- `result = df_filtered[['col_a', 'new_col']]` (Выбирает 2 колонки)

Polars vs. Pandas

Polars:

- `plan = pl.scan_csv('big_file.csv').lazy()` (Заметьте, `scan_csv` даже не читает файл, а просто "смотрит" на него)
- `plan = plan.with_columns((pl.col('col_a') * 2).alias('new_col'))`
- Ничего не произошло...
- `plan = plan.filter(pl.col('col_b') > 10)`
- Ничего не произошло.....
- `plan = plan.select(['col_a', 'new_col'])`
- Ничего не произошло.....
- `result = plan.collect()`
- Ага, пользователю в итоге нужны только колонки `col_a` и `new_col`, и только для строк, где `col_b > 10`. При этом `new_col` зависит от `col_a`

Polars vs. Pandas

- Я начну читать CSV, но буду брать из него *только* колонки `col_a` и `col_b`
- Я буду читать строки *по одной* и *сразу* проверять условие `col_b > 10`
- *Только* для тех строк, что прошли фильтр, я посчитаю `col_a * 2` и сформирую `new_col`
- Отдам пользователю результат

Matplotlib


- Matplotlib - это широко используемая библиотека визуализации данных на Python, которая служит основой для многих других библиотек визуализации
- Matplotlib предназначен для создания статических, анимированных и интерактивных визуализаций на Python
- Широко используется для построения графиков, диаграмм и рисунков, что делает его бесценным для анализа и представления данных

Базовые компоненты

- **Рисунок (Figure):** Общее окно или страница, содержащая один или несколько графиков. Можно считать, что это холст
- **Оси (Axes):** Отдельный график в пределах рисунка. Каждая ось имеет свои оси x и y , метки и может содержать несколько линий или серий данных
- **Художник (Artist):** Любой объект, являющийся частью фигуры, например линии, текст, маркеры и т. д

```
import matplotlib.pyplot as plt


# Example: Simple Line Plot
x = [1, 2, 3, 4, 5]
y = [2, 3, 5, 7, 11]
plt.plot(x, y)
plt.title('Simple Line Plot')
plt.xlabel('X-axis')
plt.ylabel('Y-axis')
plt.show()
```



Кастомизация


Matplotlib позволяет широко настраивать графики. Вы можете настраивать цвета, маркеры, стили линий, добавлять аннотации, легенды и линии сетки, чтобы улучшить наглядность и представление визуализации

```
plt.plot(x, y, color='blue', marker='o',  
         linestyle='--', linewidth=2, markersize=5)  
plt.grid()
```



Subplots

С помощью функции `subplots()` можно создать несколько графиков в рамках одного рисунка, что удобно для сравнения различных наборов данных или демонстрации различий между несколькими графиками





```
fig, axs = plt.subplots(2, 2) # 2 rows, 2 columns
# Обратите внимание: мы вызываем .plot() у объекта axs[0, 0]
axs[0, 0].plot(x, y) # Top-left plot
axs[0, 1].bar(x, y) # Top-right plot
axs[1, 0].scatter(x, y) # Bottom-left plot
plt.show()
```



Типы графиков

- Matplotlib поддерживает широкий спектр графиков, включая:
 - Линейные графики (line plots)
 - Графики рассеяния (scatter plots)
 - Столбчатые диаграммы (bar plots)
 - Гистограммы (histograms)
 - Круговые диаграммы (pie charts)
 - Коробчатые диаграммы (box plots)
 - Тепловые карты (heatmaps)
- Каждый тип графика можно настроить с помощью заголовков, меток, легенд и различных стилей

Line Plot and Scatter Plot with Noise




Bar Plot and Histogram




Pie Chart and Heatmap

Pie Chart




Heatmap



Интеграция с другими библиотеками

```
import pandas as pd

df = pd.DataFrame({'x': [1, 2, 3, 4, 5],
                   'y': [2, 3, 5, 7, 11]})
df.plot(x='x', y='y', kind='line')
plt.show()
```



Seaborn

- Seaborn - это мощная библиотека визуализации данных, построенная на базе Matplotlib, которая упрощает процесс создания информативных и привлекательных статистических графиков
- Предоставляет высокоуровневый интерфейс для построения привлекательных и информативных статистических графиков и особенно хорошо подходит для визуализации сложных наборов данных
- Seaborn поставляется с несколькими встроенными темами и цветовыми палитрами для повышения эстетической привлекательности графиков и предлагает функции для визуализации одномерных и двумерных распределений, категориальных данных и моделей линейной регрессии

- **Статистические графики:** Легко создавайте такие графики, как коробчатые диаграммы, скрипочные диаграммы, тепловые карты и парные графики, которые помогают понять распределение и взаимосвязи в данных
- **Встроенные темы:** Seaborn предоставляет множество цветовых палитр и стилей, которые можно легко применить к вашим графикам
- **Интеграция с Pandas:** Seaborn легко работает с Pandas DataFrames, позволяя легко строить графики для сложных наборов данных

```
import seaborn as sns
import pandas as pd
import matplotlib.pyplot as plt


# Sample dataset: Titanic dataset available in Seaborn
titanic = sns.load_dataset('titanic')

# Display the first few rows of the DataFrame to understand its structure
print(titanic.head())
```


	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	\
0	0	3	male	22.0	1	0	7.2500	S	Third	
1	1	1	female	38.0	1	0	71.2833	C	First	
2	1	3	female	26.0	0	0	7.9250	S	Third	
3	1	1	female	35.0	1	0	53.1000	S	First	
4	0	3	male	35.0	0	0	8.0500	S	Third	

	who	adult_male	deck	embark_town	alive	alone
0	man	True	NaN	Southampton	no	False
1	woman	False	C	Cherbourg	yes	False
2	woman	False	NaN	Southampton	yes	True
3	woman	False	C	Southampton	yes	False
4	man	True	NaN	Southampton	no	True


```
plt.figure(figsize=(10, 6))
sns.barplot(x='class', y='fare',
            data=titanic, estimator=lambda x: x.mean())
plt.title('Average Fare Paid by Class')
plt.show()
```



```
plt.figure(figsize=(10, 6))
sns.boxplot(x='class', y='age',
            data=titanic, palette='Set3')
plt.title('Age Distribution by Class')
plt.show()
```



```
plt.figure(figsize=(10, 6))
sns.countplot(x='survived', hue='class',
              data=titanic, palette='Set2')
plt.title('Survival Count by Class')
plt.show()
```



SciPy

- SciPy - это библиотека Python, используемая для научных и технических вычислений
- Построена на базе NumPy и расширяет ее возможности, предоставляя дополнительные функции для оптимизации, интегрирования, интерполяции, решения задач с собственными значениями и других задач, связанных с научными вычислениями
- SciPy широко используется в таких областях, как наука о данных, инженерия и математика, благодаря богатому набору численных методов

Основные функции

- **Оптимизация:** Функции для минимизации или максимизации функций (например, `scipy.optimize`)
- **Интеграция:** Инструменты численного интегрирования (например, `scipy.integrate`)
- **Линейная алгебра:** Расширенные операции линейной алгебры (например, `scipy.linalg`)
- **Обработка сигналов:** Инструменты для фильтрации и обработки сигналов (например, `scipy.signal`)
- **Статистические функции:** Распределения вероятностей и статистические тесты (например, `scipy.stats`)

Пример

```
from scipy import stats

# Данные о зарплатах двух отделов
sales = [70, 72, 75, 68, 78]
engineering = [80, 85, 82, 90, 78]

# Т-тест: есть ли статистически значимая разница?
t_stat, p_value = stats.ttest_ind(sales, engineering)

print(f"P-value: {p_value:.4f}")
# P-value: 0.0054 (Если < 0.05, разница значима)
```

Sklearn

- Scikit-learn (более известная как Sklearn) - это мощная и широко используемая библиотека Python для машинного обучения
- Предоставляет простые и эффективные инструменты для добычи данных, анализа данных и задач машинного обучения
- Sklearn построен на базе NumPy, SciPy и Matplotlib, что делает его ключевой частью экосистемы Python для науки о данных

Основные возможности

- **Обучение с учителем:** Реализует многие популярные алгоритмы машинного обучения для классификации (например, Decision Trees, SVM) и регрессии (например, Linear Regression)
- **Обучение без учителя:** Предлагает алгоритмы кластеризации, такие как K-means, иерархическая кластеризация и PCA (анализ главных компонент) для уменьшения размерности
- **Предобработка данных:** Инструменты для масштабирования, нормализации данных и кодирования категориальных переменных
- **Выбор модели:** Функции, такие как кросс-валидация и grid search, для оценки и точной настройки моделей
- **Конвейеры:** Упрощение рабочих процессов за счет объединения в цепочку этапов предварительной обработки и моделей

```
import sklearn
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import accuracy_score

# Load the Iris dataset
iris = load_iris()
X, y = iris.data, iris.target

# Split the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# Create a Decision Tree classifier
clf = DecisionTreeClassifier()

# Train the classifier on the training data
clf.fit(X_train, y_train)

# Make predictions on the test data
y_pred = clf.predict(X_test)


# Evaluate the accuracy of the model
accuracy = accuracy_score(y_test, y_pred)
print(f"Model accuracy: {accuracy:.2f}")
```

Model accuracy: 1.00

```
from sklearn.tree import plot_tree
```

```
plt.figure(figsize=(12, 8)) # Set the figure size  
plot_tree(clf, filled=True, feature_names=iris.feature_names, class_names=iris.target_names, rounded=True)  
plt.title("Decision Tree for Iris Dataset")  
plt.show()
```

Decision Tree for Iris Dataset



Спасибо за внимание!