

CPython

Гейне М.А.

07.11.2025

CPython - это эталонная реализация языка программирования Python, написанная на языке C. Большинство людей, говоря о Python, имеют в виду именно его, и он является интерпретатором Python по умолчанию. Он компилирует код Python в байткод, который затем запускается на виртуальной машине CPython, что делает его наиболее широко используемой средой выполнения Python.

Почему C?

Компиляторы бывают двух видов:


1. Самостоятельные компиляторы - это компиляторы, написанные на языке, который они компилируют, например, компилятор Go
2. Source-to-source компиляторы - это компиляторы, написанные на другом языке, для которого уже есть компилятор

Любой компилируемый язык проходит стадию сборки транспайлером: чтобы собрать свой новый компилятор, нужен другой компилятор. CPython решил сохранять это наследие

Компилируемый или интерпретируемый?

Строго говоря, Python и компилируемый, и интерпретируемый одновременно:

1. **Компиляция в байткод:** Когда запускается скрипт Python, CPython сначала компилирует его в байткод, который является более низкоуровневым, платформенно-независимым представлением кода.
2. **Интерпретация:** Этот байткод затем интерпретируется виртуальной машиной CPython, которая выполняет инструкции в системе.



Структура CPython

cpython/

— Doc	← Source for the documentation
— Grammar	← The computer-readable language definition
— Include	← The C header files
— Lib	← Standard library modules written in Python
— Mac	← macOS support files
— Misc	← Miscellaneous files
— Modules	← Standard Library Modules written in C
— Objects	← Core types and the object model
— Parser	← The Python parser source code
— PC	← Windows build support files
— PCbuild	← Windows build support files for older Windows versions
— Programs	← Source code for the python executable and other binaries
— Python	← The CPython interpreter source code
— Tools	← Standalone tools useful for building or extending Python

Документация

В `Doc/reference` содержатся полные описания всех возможностей Python, которые служат основой для официальной справки на docs.python.org

```
cpython/Doc/reference
├── compound_stmts.rst
├── datamodel.rst
├── executionmodel.rst
├── expressions.rst
├── grammar.rst
├── import.rst
├── index.rst
├── introduction.rst
├── lexical_analysis.rst
├── simple_stmts.rst
└── toplevel_components.rst
```

Грамматика

Вся спецификация языка Python записана в одном файле `Grammar/Grammar`. Грамматика Python записана в расширенных формах Бэкуса-Наура (EBNF)

```
with_stmt: 'with' with_item (',' with_item)* ':' suite
with_item: test ['as' expr]
```


Токены

В дополнение к грамматике в файле `Grammar/Tokens` описаны токены: все возможные уникальные конечные выражения (листья AST-дерева) языка. Среди них

LPAR	'('
RPAR	')'
LSQB	'['
RSQB	']'
COLON	':'
COMMA	','
SEMI	';'

Рассмотрим пример:

```
# Hello world!  
def my_function():  
    pass
```

```
$ ./python.exe -m tokenize -e test_tokens.py
```

0,0-0,0:	ENCODING	'utf-8'
1,0-1,14:	COMMENT	'# Hello world!'
1,14-1,15:	NL	'\n'
2,0-2,3:	NAME	'def'
2,4-2,15:	NAME	'my_function'
2,15-2,16:	LPAR	'('
2,16-2,17:	RPAR	')'
2,17-2,18:	COLON	':'
2,18-2,19:	NEWLINE	'\n'
3,0-3,3:	INDENT	' '
3,3-3,7:	NAME	'pass'
3,7-3,8:	NEWLINE	'\n'
4,0-4,0:	DEDENT	''
4,0-4,0:	ENDMARKER	''


```
$ ./python.exe -d test_tokens.py

Token NAME/'def' ... It's a keyword
  DFA 'file_input', state 0: Push 'stmt'
  DFA 'stmt', state 0: Push 'compound_stmt'
  DFA 'compound_stmt', state 0: Push 'funcdef'
  DFA 'funcdef', state 0: Shift.
Token NAME/'my_function' ... It's a token we know
  DFA 'funcdef', state 1: Shift.
Token LPAR/ '(' ... It's a token we know
  DFA 'funcdef', state 2: Push 'parameters'
  DFA 'parameters', state 0: Shift.
Token RPAR/ ')' ... It's a token we know
  DFA 'parameters', state 1: Shift.
  DFA 'parameters', state 2: Direct pop.
Token COLON/ ':' ... It's a token we know
  DFA 'funcdef', state 3: Shift.
Token NEWLINE/ '\n' ... It's a token we know
  DFA 'funcdef', state 5: [switch func_body_suite to suite] Push 'suite'
  DFA 'suite', state 0: Shift.
Token INDENT/ '\n' ... It's a token we know
  DFA 'suite', state 1: Shift.
Token NAME/ 'pass' ... It's a keyword
  DFA 'suite', state 3: Push 'stmt'
...
ACCEPT.
```

Abstract Syntax Tree (AST)

Абстрактное синтаксическое дерево (AST) - это древовидное представление синтаксической структуры исходного кода. В AST:

- Каждый **узел** представляет собой конструкцию в исходном коде, такую как выражения, операторы и управляющие структуры.
- Структура **дерева** отражает иерархическую, вложенную природу языков программирования, где одни утверждения или выражения содержат другие.



Объекты и типы данных

Каждая сущность в Python - это объект, и каждый объект имеет связанный с ним тип данных **type**.


- В Python все, включая целые числа, строки, функции, классы и модули, представлено в виде объекта. Такая конструкция позволяет Python быть очень гибким, поскольку с каждым элементом можно взаимодействовать единообразно
- Каждый объект представлен внутренне структурой `PyObject`, которая является базовой структурой для всех объектов Python в CPython

- В CPython используется сильная и динамическая система типов, то есть типы ассоциируются с объектами (а не с переменными), а проверка типов происходит во время выполнения
- Каждый объект имеет атрибут `type`, указывающий на объект типа (например, `int`, `str`, `list`). Этот объект типа содержит информацию о том, как манипулировать или оперировать с экземплярами данного типа
- Каждый объект основан на C-структуре `PyObject`, которая содержит базовую информацию, такую как количество ссылок и указатели типов
- `PyTypeObject` определяет тип данных и включает методы для операций (таких как сложение или представление строк), характерных для этого типа

Пример:

Целочисленные объекты в CPython

- Для `x = 5`, CPython создает объект `int`
- У `int` есть:
 - Счетчик ссылок (для отслеживания количества ссылок на него)
 - Указатель на объект *типа* `int`, который определяет методы, специфичные для целых чисел (например, сложение или сравнение)
 - Непосредственное значение `ob_val`



Код как объект

Помимо привычных нам данных, упакованных в объект, в Python также возможно рассмотреть исполняемый код в виде объекта, что раскрывает ряд дополнительных возможностей. К примеру, такое представление позволяет использовать функции в качестве объектов первого класса: передавать их в функции в качестве аргументов, возвращать их как значения, связывать с переменными и так далее

Code Objects

Code Object в Python представляет собой скомпилированный байткод для блока кода (например, функции, класса или модуля). Объекты кода неизменяемы и содержат важную информацию, необходимую для выполнения кода

Ключевые атрибуты Code Object включают:

- **co_code** : Байткод, который будет выполняться
- **co_varnames** : Имена локальных переменных, используемых в блоке кода
- **co_names** : Имена любых других переменных или функций, на которые ссылается блок кода
- **co_consts** : Константы, используемые в коде, как литералы
- **co_filename** , **co_name** и **co_firstlineno** : Информация о том, откуда взят код (например, имя файла, имя функции и номер строки)

Важно: Code Object сам по себе ещё не является вызываемым объектом

Функции

Объект **функции** в Python - это вызываемый объект, который оборачивает объект кода вместе с дополнительным контекстом, таким как глобальная область видимости функции и значения по умолчанию для параметров. При определении функции Python:

1. Создает **Code Object** для тела функции
2. Оборачивает этот объект в **объект функции**, который включает такие атрибуты, как:
 - `__code__`: Ссылка на объект кода
 - `__globals__`: Ссылка на глобальную область видимости, в которой была определена функция
 - `__defaults__` и `__kwdefaults__`: Значения аргументов по умолчанию
 - `__closure__`: Ссылка на любые включаемые переменные, если функция является замыкающей

Фреймы

Объект **frame** создается при каждом вызове функции, представляя собой однократное выполнение этой функции. Объекты фрейма отслеживают:

- **Code Object**: Конкретный выполняемый код
- **Локальные и глобальные пространства имен**:
Сопоставления для локальных и глобальных переменных
- **Предыдущий фрейм**: Ссылка на фрейм вызывающей функции, позволяющая отследить вызовы
- **Стек и состояние исчислений**: Временные данные, необходимые для оценки выражений внутри функции.

Фреймы очень важны для отслеживания **контекста выполнения** во время вызовов функций и управления **стеком вызовов**. Каждый фрейм соответствует одному вызову функции и содержит:

- **f_locals** : Словарь локальных переменных для этого фрейма
- **f_globals** : Глобальные переменные, доступные в области видимости этого фрейма
- **f_back** : Ссылка на предыдущий фрейм в стеке вызовов (т. е. на функцию, которая вызвала этот фрейм)

После завершения работы функции ее фрейм удаляется из стека вызовов, освобождая ресурсы. Фреймы также важны для отладки и трассировки стека, поскольку они обеспечивают подробный контекст для каждого уровня вызова функции

Стек вызовов

Стек вызовов - это стековая структура данных, хранящая информацию об активных вызовах функций в программе. При каждом вызове функции создается **фрейм**, который помещается в стек вызовов и представляет собой контекст функции (локальные переменные, аргументы и т. д.). Когда функция завершает свою работу, ее фрейм сбрасывается со стека, и управление возвращается к вызывающей функции.

- **Создание фрейма:** Каждый вызов функции создает новый **фрейм**, который содержит все необходимые данные для этого вызова (локальные и глобальные переменные, адрес возврата и т. д.)
- **Рост стека:** Когда внутри функции вызывается новая функция, фрейм для новой функции добавляется в верх стека
- **Уменьшение стека:** Когда функция возвращается, ее фрейм удаляется из стека и возобновляется выполнение в фрейме вызывающей функции
- **Рекурсия и глубина стека:** Поскольку каждый вызов функции добавляет фрейм в стек, рекурсивные функции занимают место в стеке при каждом рекурсивном вызове. В Python существует максимальная глубина **рекурсии** (по умолчанию около 1 000), ограничивающая количество фреймов, которые могут быть добавлены в стек. Глубокая рекурсия сверх этого предела приводит к `RecursionError`.

Стек данных (Evaluation stack)

Внутри каждого фрейма есть **стек данных** (также называемый стеком **операнд**), используемый для управления промежуточными значениями во время оценки выражений. Этот стек специфичен для **модели виртуальной машины Python (PVM)**, основанной на стеках, где каждая операция кладёт или вынимает значения из стека для оценки выражений

Стек данных является ключевым в **выполнении байткода**:

- **Push**: Каждый операнд (например, переменные, литералы, результаты подвыражений) кладётся в стек оценки
- **Pop**: Каждая операция (например, сложение, вызов функции) снимает операнды со стека, выполняет операцию и помещает результат обратно в стек

В стеке временно хранятся промежуточные значения, которые будут использоваться для дальнейших операций в сложных выражениях

Пример стека данных

Для выражения $3 + 5 * 2$, Python оценивает его, сначала помещая операнды и операторы в стек, а затем выгружая их по мере необходимости для вычисления результата в соответствии с приоритетом операторов.

Инструкции байткода:

1. Поместить 3 в стек
2. Переместите 5 в стек
3. Переместите 2 в стек
4. Умножьте $5 * 2$ (извлечь 5 и 2 , положить 10)
5. Сложить $3 + 10$ (извлечь 3 и 10 , положить 13)

Управление памятью

В отличие от многих низкоуровневых языков, где задача управления памятью ложится на программиста, в Python за управление памятью отвечает интерпретатор, задействуя два механизма:

1. Подсчёт ссылок
2. Сборка мусора

Подсчет ссылок

- Каждый объект в Python имеет **счетчик ссылок**, который отслеживает, сколько ссылок на него указывают. Этот счетчик увеличивается при создании новой ссылки (например, при присвоении объекта переменной) и уменьшается, когда ссылка удаляется или выходит из области видимости
- Когда счетчик ссылок объекта падает до нуля, это означает, что на объект не осталось ссылок, поэтому CPython может освободить от него память

```
x = [1, 2, 3] # Reference count for list object increases to 1
y = x        # Reference count for list object increases to 2
del x        # Reference count for list object decreases to 1
del y        # Reference count for list object decreases to 0 (memory is freed)
```

Garbage Collection (GC)

Хотя подсчет ссылок работает хорошо, он может дать сбой в ситуациях с **круговыми ссылками** - например, два объекта, которые ссылаются друг на друга. Циклические ссылки не могут быть решены только подсчетом ссылок, поскольку каждый объект в цикле всегда имеет ненулевой счетчик ссылок

В Python есть дополнительный **сборщик мусора**, который периодически ищет и освобождает круговые ссылки. Этот сборщик мусора:

- Работает как **поколенческий сборщик мусора**, который группирует объекты в три поколения на основе их "возраста" (как долго они существуют)
- Сборщик чаще фокусируется на младших поколениях, поскольку они чаще содержат объекты, которые можно быстро деаллоцировать

Поколения объектов

Сборщик мусора (GC) в Python делит объекты на **три поколения** в зависимости от их возраста и продолжительности жизни. Идея состоит в том, что **молодые объекты** (созданные недавно) с большей вероятностью станут недоступными раньше, в то время как **старые объекты** сохраняются дольше и реже нуждаются в сборе

Поколение 0 (самое молодое поколение):

- Это начальное, "молодое" поколение, в котором размещаются новые объекты
- Объекты в этом поколении недолговечны, поэтому многие из них быстро становятся недоступными и требуют сбора
- Сборщик мусора часто сканирует поколение 0, что делает его более эффективным для быстрого сбора объектов, которые больше не используются

Поколение 1 (среднее поколение):

- Если объект пережил цикл сборки мусора в поколении 0, он переходит в поколение 1
- Поколение 1 сканируется реже, чем поколение 0, потому что объекты, пережившие первоначальную сборку, с меньшей вероятностью станут недоступными
- Это поколение является "золотой серединой" для объектов, которые могут существовать более длительное время, но все равно могут быть отброшены

Поколение 2 (старшее поколение):

- Объекты, пережившие несколько циклов сборки мусора в поколении 1, переходят в поколение 2
- Поколение 2 сканируется еще реже, исходя из предположения, что эти старые объекты долгоживущие наименее вероятно станут мусором
- Это поколение содержит объекты, которые либо необходимы на протяжении всего времени работы программы (например, некоторые глобальные переменные и данные модулей), либо являются относительно статичными

Модель поколений использует **гипотезу поколений**: идею о том, что большинство объектов, создаваемых программой, либо очень недолговечны, либо будут существовать в течение всего времени работы программы. Благодаря такому подходу сборщик мусора Python может более эффективно направлять свои ресурсы:

- **Частый сбор поколения 0** отлавливает и удаляет многие недолговечные объекты на ранней стадии, минимизируя использование памяти
- **Нечастый сбор поколений 1 и 2** снижает расходы на повторную проверку долгоживущих объектов, поскольку они с меньшей вероятностью будут нуждаться в сборе

Memory Pools and Arenas

Чтобы повысить эффективность использования памяти, Python использует механизм **пула памяти**. Вместо того чтобы напрямую взаимодействовать с операционной системой при каждом выделении, Python управляет памятью с помощью **пулов** и **арен**:

- **Пулы**: Небольшие объекты (обычно < 512 байт) выделяются из пулов памяти, которые представляют собой блоки памяти, предварительно выделенные Python. Это уменьшает фрагментацию и ускоряет выделение памяти
- **Арены**: Пулы организованы в арены, которые представляют собой более крупные куски памяти, выделяемые ОС. Каждая арена делится на пулы для объектов разного размера

Global Interpreter Lock (GIL)

Глобальная блокировка интерпретатора (GIL) - это мьютекс, который защищает доступ к объектам Python в CPython, обеспечивая одновременное выполнение байткода Python только одним потоком даже на многоядерных системах. GIL упрощает управление памятью, особенно для системы подсчета ссылок в CPython, но ограничивает истинную многопоточную производительность для задач, привязанных к процессору

Почему существует GIL?

GIL был введен для упрощения управления памятью путем защиты внутренних структур памяти Python от одновременного доступа, что позволяет CPython управлять памятью без сложных механизмов потокобезопасности

1. **Подсчет ссылок:** CPython использует подсчет ссылок для управления выделением и удалением памяти для объектов. Без GIL каждому потоку потребовался бы свой собственный механизм для безопасного управления подсчетом ссылок, что может привести к значительным накладным расходам и сложности
2. **Компромисс с производительностью:** GIL упрощает и ускоряет написание расширений на C, не требуя дополнительной синхронизации в коде, что было преимуществом исторически, когда большинство процессоров были одноядерными

3. **Concurrency vs Parallelism:** Python не поддерживает concurrency (выполнение нескольких задач) с помощью GIL, но поддерживает parallelism (одновременное выполнение нескольких задач на разных ядрах) для задач, привязанных к процессору

Поскольку только один поток может выполнять байткод Python в любой момент времени, потоки Python, привязанные к процессору, не получают преимущества от использования нескольких ядер. В результате программы, требовательные к процессору, могут не получить значительного прироста скорости за счет дополнительных потоков

Спасибо за внимание